

机器学习实战教程（十一）：线性回归基础篇之预测鲍鱼年龄

🕒 2017年11月19日 17:09:51 🗨 68 👁 15,893 °C 🛠 编辑



一、前言

前面的文章介绍了很多分类算法，分类的目标变量是标称型数据，而本文将会对连续型的数据做出预测。主要讲解简单的线性回归和局部加权线性回归，并通过预测鲍鱼年龄的实例进行实战演练。

二、什么是回归？

回归的目的是预测数值型的目标值。最直接的办法是依据输入写出一个目标值的计算公式。假如你想预测小姐姐男友汽车的功率，可能会这么计算：

$$\text{HorsePower} = 0.0015 * \text{annualSalary} - 0.99 * \text{hoursListeningToPublicRadio}$$

写成中文就是：

$$\text{小姐姐男友汽车的功率} = 0.0015 * \text{小姐姐男友年薪} - 0.99 * \text{收听公共广播的时间}$$

这就是所谓的回归方程（regression equation），其中的0.0015和-0.99称为回归系数（regression weights），求这些回归系数的过程就是回归。一旦有了这些回归系数，再给定输入，做预测就非常容易了。具体的做法是用回归系数乘以输入值，再将结果全部加在一起，就得到了预测值。

说到回归，一般都是指线性回归（linear regression），所以本文里的回归和线性回归代表同一个意思。线性回归意味着可以将输入项分别乘以一些常量，再将结果加起来得到输出。需要说明的

是，存在另一种成为非线性回归的回归模型，该模型不认同上面的做法，比如认为输出可能是输入的乘积。这样，上面的功率计算公式也可以写做：

$$\text{HorsePower} = 0.0015 * \text{annualSalary} / \text{hoursListeningToPublicRadio}$$

这就是一个非线性回归的例子，本文对此不做深入讨论。

三、揭开回归的神秘面纱

1、用线性回归找到最佳拟合直线

应该怎么从一大堆数据里求出回归方程呢？假定输入数据存放在矩阵X中，结果存放在向量y中：

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{bmatrix}, y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

而回归系数存放在向量w中：

$$\omega = \begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \end{bmatrix}$$

那么对于给定的数据x1，即矩阵X的第一列数据，预测结果u1将会通过如下公式给出：

$$u_1 = \begin{bmatrix} x_{11} \\ x_{21} \\ x_{31} \end{bmatrix}^T * \begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \end{bmatrix}$$

现在的问题是，手里有数据矩阵X和对应的标签向量y，怎么才能找到w呢？一个常用的方法就是找出使误差最小的w。这里的误差是指预测u值和真实y值之间的差值，使用该误差的简单累加将使得正差值和负差值相互抵消，所以我们采用平方误差。

平方误差和可以写做：

$$\sum_{i=1}^m (y_i - x_i^T \omega)^2$$

用矩阵表示还可以写做：

$$(y - X\omega)^T (y - X\omega)$$

为啥能这么变化，记住一个前提：若x为向量，则默认x为列向量， x^T 为行向量。将上述提到的数据矩阵X和标签向量y带进去，就知道为何这么变化了。

在继续推导之前，我们要先明确一个目的：找到w，使平方误差和最小。因为我们认为平方误差和越小，说明线性回归拟合效果越好。

现在，我们用矩阵表示的平方误差和对w进行求导：

$$\begin{aligned} & \frac{\partial (y - X\omega)^T (y - X\omega)}{\partial \omega} \\ &= \frac{\partial (y^T y - y^T X\omega - \omega^T X^T y + \omega^T X^T X\omega)}{\partial \omega} \\ &= \frac{\partial y^T y}{\partial \omega} - \frac{\partial y^T X\omega}{\partial \omega} - \frac{\partial \omega^T X^T y}{\partial \omega} + \frac{\partial \omega^T X^T X\omega}{\partial \omega} \\ &= 0 - X^T y - \frac{\partial (\omega^T X^T y)^T}{\partial \omega} + 2X^T X\omega \\ &= 0 - X^T y - \frac{\partial y^T X\omega}{\partial \omega} + 2X^T X\omega \\ &= 0 - X^T y - X^T y + 2X^T X\omega \\ &= 2X^T (y - X\omega) \end{aligned}$$

如果对于矩阵求不熟悉的，可以移步这里：[点击查看](#)

令上述公式等于0，得到：

$$\hat{\omega} = (X^T X)^{-1} X^T y$$

w上方的小标记表示，这是当前可以估计出的w的最优解。从现有数据上估计出的w可能并不是数据中的真实w值，所以这里使用了一个"帽"符号来表示它仅是w的一个最佳估计。

值得注意的是，上述公式中包含逆矩阵，也就是说，这个方程只在逆矩阵存在的时候使用，也就是这个矩阵是一个方阵，并且其行列式不为0。

述的最佳w求解是统计学中的常见问题，除了矩阵方法外还有很多其他方法可以解决。通过调用NumPy库里的矩阵方法，我们可以仅使用几行代码就完成所需功能。该方法也称作OLS，意思是“普

通小二乘法”（ordinary least squares）。

我们先看下数据集，数据下载地址：[数据集下载](#)

1	1.000000	0.067732	3.176513
2	1.000000	0.427810	3.816464
3	1.000000	0.995731	4.550095
4	1.000000	0.738336	4.256571
5	1.000000	0.981083	4.560815
6	1.000000	0.526171	3.929515
7	1.000000	0.378887	3.526170
8	1.000000	0.033859	3.156393
9	1.000000	0.132791	3.110301
10	1.000000	0.138306	3.149813
11	1.000000	0.247809	3.476346
12	1.000000	0.648270	4.119688
13	1.000000	0.731209	4.282233
14	1.000000	0.236833	3.486582
15	1.000000	0.969788	4.655492
16	1.000000	0.607492	3.965162
17	1.000000	0.358622	3.514900
18	1.000000	0.147846	3.125947
19	1.000000	0.637820	4.094115
20	1.000000	0.230372	3.476039
21	1.000000	0.070237	3.210610
22	1.000000	0.067154	3.190612
23	1.000000	0.925577	4.631504
24	1.000000	0.717733	4.295890
25	1.000000	0.015371	3.085028
26	1.000000	0.335070	3.448080
27	1.000000	0.040486	3.167440
28	1.000000	0.212575	3.364266
29	1.000000	0.617218	3.993482
30	1.000000	0.541196	3.891471
31	1.000000	0.045353	3.143259
32	1.000000	0.126762	3.114204

第一列都为1.0，即x0。第二列为x1，即x轴数据。第三列为x2，即y轴数据。首先绘制下数据，看下数据分布。编写代码如下：

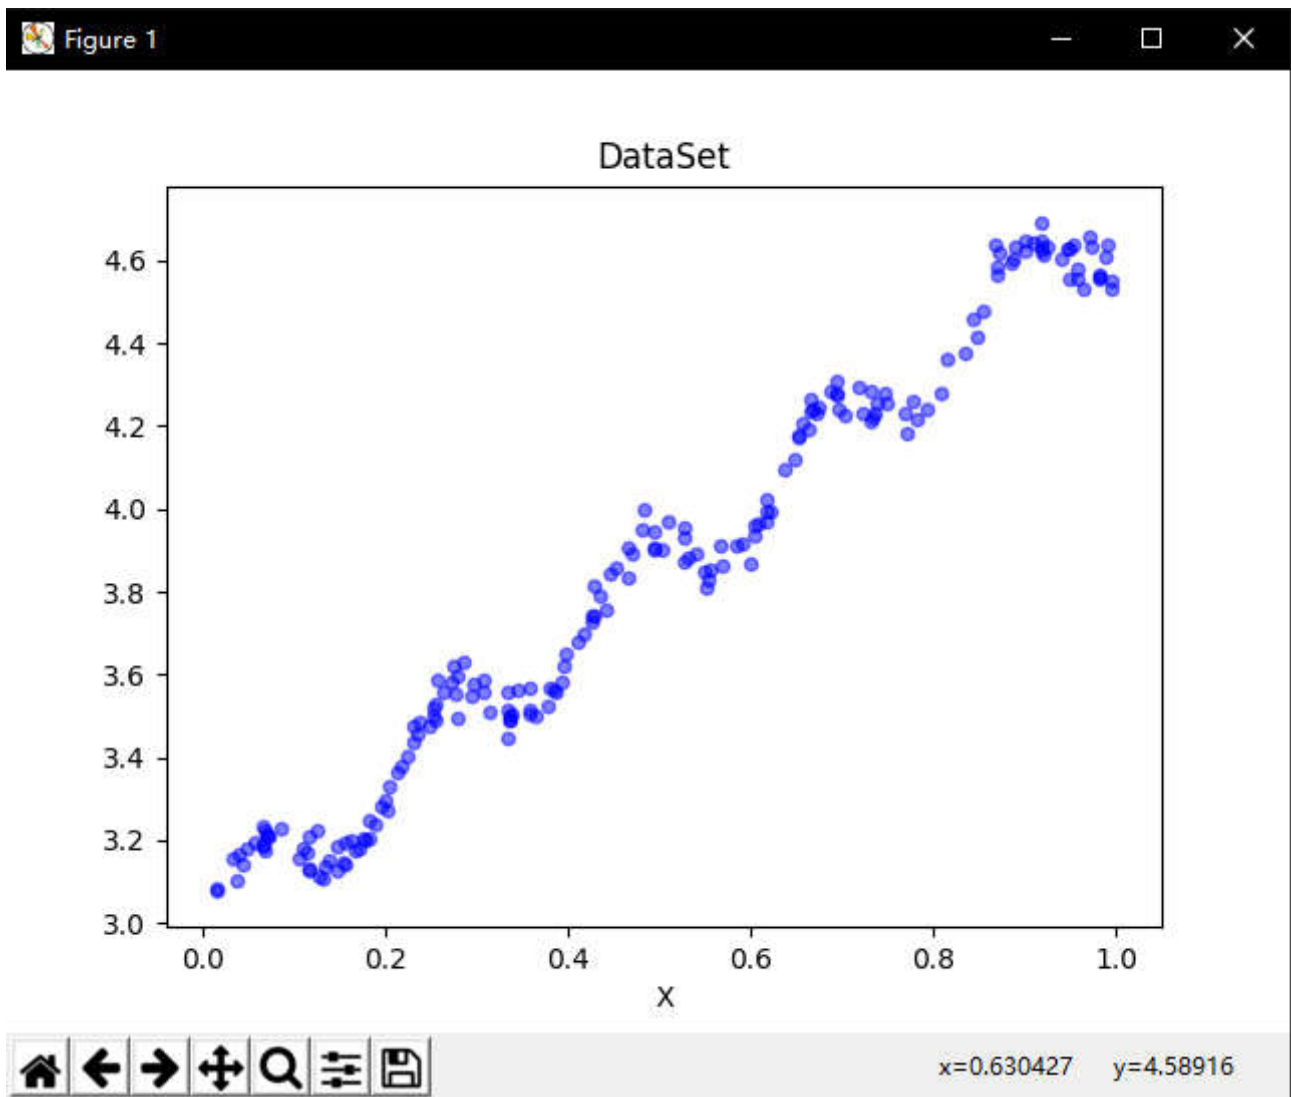
	Python
1	# -*- coding:utf-8 -*-
2	import matplotlib.pyplot as plt
3	import numpy as np
4	
5	def loadDataSet(fileName):
6	"""
7	函数说明:加载数据
8	Parameters:
9	fileName - 文件名
10	Returns:
11	xArr - x数据集
12	yArr - y数据集
13	Website:
14	https://www.cuijiahua.com/

```

15     Modify:
16         2017-11-12
17     """
18
19     numFeat = len(open(fileName).readline().split('\t')) - 1
20     xArr = []; yArr = []
21     fr = open(fileName)
22     for line in fr.readlines():
23         lineArr = []
24         curLine = line.strip().split('\t')
25         for i in range(numFeat):
26             lineArr.append(float(curLine[i]))
27         xArr.append(lineArr)
28         yArr.append(float(curLine[-1]))
29     return xArr, yArr
30
31 def plotDataSet():
32     """
33     函数说明:绘制数据集
34     Parameters:
35         无
36     Returns:
37         无
38     Website:
39         https://www.cuijiahua.com/
40     Modify:
41         2017-11-12
42     """
43     xArr, yArr = loadDataSet('ex0.txt')           #加载数据集
44     n = len(xArr)                                  #数据个数
45     xcord = []; ycord = []                         #样本点
46     for i in range(n):
47         xcord.append(xArr[i][1]); ycord.append(yArr[i])   #样本点
48     fig = plt.figure()
49     ax = fig.add_subplot(111)                     #添加subplot
50     ax.scatter(xcord, ycord, s = 20, c = 'blue', alpha = .5) #绘制样本点
51     plt.title('DataSet')                           #绘制title
52     plt.xlabel('X')
53     plt.show()
54
55 if __name__ == '__main__':
56     plotDataSet()

```

运行代码如下：



通过可视化数据，我们可以看到数据的分布情况。接下来，让我们根据上文中推导的回归系数计算方法，求出回归系数向量，并根据回归系数向量绘制回归曲线，编写代码如下：

Python

```

1 # -*- coding:utf-8 -*-
2 import matplotlib.pyplot as plt
3 import numpy as np
4
5 def loadDataSet(fileName):
6     """
7     函数说明:加载数据
8     Parameters:
9         fileName - 文件名
10    Returns:
11        xArr - x数据集
12        yArr - y数据集
13    Website:
14        https://www.cuijiahua.com/
15    Modify:
16        2017-11-12
17    """
18    numFeat = len(open(fileName).readline().split('\t')) - 1
19    xArr = []; yArr = []
20    fr = open(fileName)
21    for line in fr.readlines():
22        lineArr = []
23        curLine = line.strip().split('\t')
24        for i in range(numFeat):
25            lineArr.append(float(curLine[i]))
26        xArr.append(lineArr)


```

```

27         yArr.append(float(curLine[-1]))
28     return xArr, yArr
29
30 def standRegres(xArr,yArr):
31     """
32     函数说明:计算回归系数w
33     Parameters:
34         xArr - x数据集
35         yArr - y数据集
36     Returns:
37         ws - 回归系数
38     Website:
39         https://www.cuijiahua.com/
40     Modify:
41         2017-11-12
42     """
43     xMat = np.mat(xArr); yMat = np.mat(yArr).T
44     xTx = xMat.T * xMat                                     #根据文中推导的公示计算回归系数
45     if np.linalg.det(xTx) == 0.0:
46         print("矩阵为奇异矩阵,不能求逆")
47         return
48     ws = xTx.I * (xMat.T*yMat)
49     return ws
50
51 def plotRegression():
52     """
53     函数说明:绘制回归曲线和数据点
54     Parameters:
55         无
56     Returns:
57         无
58     Website:
59         https://www.cuijiahua.com/
60     Modify:
61         2017-11-12
62     """
63     xArr, yArr = loadDataSet('ex0.txt')                    #加载数据集
64     ws = standRegres(xArr, yArr)                           #计算回归系数
65     xMat = np.mat(xArr)                                    #创建xMat矩阵
66     vMat = np.mat(vArr)                                    #创建vMat矩阵

```

运行代码如下：



如何判断拟合曲线的拟合效果的如何呢？当然，我们可以根据自己的经验进行观察，除此之外，我们还可以使用corrcoef方法，来比较预测值和真实值的相关性。编写代码如下：

Python

```

1 # -*- coding:utf-8 -*-
2 import numpy as np
3
4 def loadDataSet(fileName):
5     """
6     函数说明:加载数据
7     Parameters:
8         fileName - 文件名
9     Returns:
10         xArr - x数据集
11         yArr - y数据集
12     Website:
13         https://www.cuijiahua.com/
14     Modify:
15         2017-11-12
16     """
17     numFeat = len(open(fileName).readline().split('\t')) - 1
18     xArr = []; yArr = []
19     fr = open(fileName)
20     for line in fr.readlines():
21         lineArr = []
22         curLine = line.strip().split('\t')
23         for i in range(numFeat):
24             lineArr.append(float(curLine[i]))
25         xArr.append(lineArr)
26         yArr.append(float(curLine[-1]))

```



```

27     return xArr, yArr
28
29 def standRegres(xArr,yArr):
30     """
31     函数说明:计算回归系数w
32     Parameters:
33         xArr - x数据集
34         yArr - y数据集
35     Returns:
36         ws - 回归系数
37     Website:
38         https://www.cuijiahua.com/
39     Modify:
40         2017-11-12
41     """
42     xMat = np.mat(xArr); yMat = np.mat(yArr).T
43     xTx = xMat.T * xMat                                     #根据文中推导的公示计算回归系数
44     if np.linalg.det(xTx) == 0.0:
45         print("矩阵为奇异矩阵,不能求逆")
46         return
47     ws = xTx.I * (xMat.T*yMat)
48     return ws
49
50 if __name__ == '__main__':
51     xArr, yArr = loadDataSet('ex0.txt')                    #加载数据集
52     ws = standRegres(xArr, yArr)                           #计算回归系数
53     xMat = np.mat(xArr)                                    #创建xMat矩阵
54     yMat = np.mat(yArr)                                    #创建yMat矩阵
55     yHat = xMat * ws
56     print(np.corrcoef(yHat.T, yMat))

```

运行结果如下：

```

102
103 if __name__ == '__main__':
104     xArr, yArr = loadDataSet('ex0.txt')
105     ws = standRegres(xArr, yArr)
106     xMat = np.mat(xArr)
107     yMat = np.mat(yArr)
108     yHat = xMat * ws
109     print(np.corrcoef(yHat.T, yMat))
110
111

```

```

[[ 1.          0.98647356]
 [ 0.98647356  1.          ]]
[Finished in 1.8s]

```

可以看到，对角线上的数据是1.0，因为yMat和自己的匹配是完美的，而YHat和yMat的相关系数为0.98。

最佳拟合直线方法将数据视为直线进行建模，具有十分不错的表现。数据当中似乎还存在其他的潜在模式。那么如何才能利用这些模式呢？我们可以根据数据来局部调整预测，下面就会介绍这种方法。

2、局部加权线性回归

线性回归的一个问题是有可能出现欠拟合现象，因为它求的是具有小均方误差的无偏估计。显而易见，如果模型欠拟合将不能取得好的预测效果。所以有些方法允许在估计中引入一些偏差，从而降

低预测的均方误差。

其中的一个方法是局部加权线性回归（Locally Weighted Linear Regression, LWLR）。在该方法中，我们给待预测点附近的每个点赋予一定的权重。与kNN一样，这种算法每次预测均需要事先选出对应的数据子集。该算法解除回归系数W的形式如下：

$$\hat{w} = (X^T W X)^{-1} X^T W y$$

其中W是一个矩阵，这个公式跟我们上面推导的公式的区别就在于W，它用来给每个点赋予权重。

LWLR使用"核"（与支持向量机中的核类似）来对附近的点赋予更高的权重。核的类型可以自由选择，最常用的核就是高斯核，高斯核对应的权重如下：

$$w(i, i) = \exp\left(\frac{|x^{(i)} - x|^2}{-2k^2}\right)$$

这样我们就可以根据上述公式，编写局部加权线性回归，我们通过改变k的值，可以调节回归效果，编写代码如下：

Python

```

1  # -*- coding:utf-8 -*-
2  from matplotlib.font_manager import FontProperties
3  import matplotlib.pyplot as plt
4  import numpy as np
5  def loadDataSet(fileName):
6      """
7      函数说明:加载数据
8      Parameters:
9          fileName - 文件名
10     Returns:
11         xArr - x数据集
12         yArr - y数据集
13     Website:https://www.cuijiahua.com/
14     Modify:
15         2017-11-12
16     """
17     numFeat = len(open(fileName).readline().split('\t')) - 1
18     xArr = []; yArr = []
19     fr = open(fileName)
20     for line in fr.readlines():
21         lineArr = []
22         curLine = line.strip().split('\t')
23         for i in range(numFeat):
24             lineArr.append(float(curLine[i]))
25         xArr.append(lineArr)
26         yArr.append(float(curLine[-1]))
27     return xArr, yArr
28
29 def plotLwlrRegression():
30     """
31     函数说明:绘制多条局部加权回归曲线
32     Parameters:
33         无
34     """


```

```

34 Returns:
35     无
36 Website:https://www.cuijiahua.com/
37 Modify:
38     2017-11-15
39     """
40 font = FontProperties(fname=r"c:\windows\fonts\simsun.ttc", size=14)
41 xArr, yArr = loadDataSet('ex0.txt') #加载数据集
42 yHat_1 = lwlrTest(xArr, xArr, yArr, 1.0) #根据局部加权线性回归计算
43 yHat_2 = lwlrTest(xArr, xArr, yArr, 0.01) #根据局部加权线性回归计算
44 yHat_3 = lwlrTest(xArr, xArr, yArr, 0.003) #根据局部加权线性回归计
45 xMat = np.mat(xArr) #创建xMat矩阵
46 yMat = np.mat(yArr) #创建yMat矩阵
47 srtInd = xMat[:, 1].argsort(0) #排序，返回索引值
48 xSort = xMat[srtInd][:,0,:]
49 fig, axs = plt.subplots(nrows=3, ncols=1,sharex=False, sharey=False, figsize=(10,8))
50 axs[0].plot(xSort[:, 1], yHat_1[srtInd], c = 'red') #绘制回归曲线
51 axs[1].plot(xSort[:, 1], yHat_2[srtInd], c = 'red') #绘制回归曲线
52 axs[2].plot(xSort[:, 1], yHat_3[srtInd], c = 'red') #绘制回归曲线
53 axs[0].scatter(xMat[:,1].flatten().A[0], yMat.flatten().A[0], s = 20, c = 'blue', alpha =
54 axs[1].scatter(xMat[:,1].flatten().A[0], yMat.flatten().A[0], s = 20, c = 'blue', alpha =
55 axs[2].scatter(xMat[:,1].flatten().A[0], yMat.flatten().A[0], s = 20, c = 'blue', alpha =
56 #设置标题,x轴label,y轴label
57 axs0_title_text = axs[0].set_title(u'局部加权回归曲线,k=1.0',FontProperties=font)
58 axs1_title_text = axs[1].set_title(u'局部加权回归曲线,k=0.01',FontProperties=font)
59 axs2_title_text = axs[2].set_title(u'局部加权回归曲线,k=0.003',FontProperties=font)
60 plt.setp(axs0_title_text, size=8, weight='bold', color='red')
61 plt.setp(axs1_title_text, size=8, weight='bold', color='red')
62 plt.setp(axs2_title_text, size=8, weight='bold', color='red')
63 plt.xlabel('X')
64 plt.show()
65 def lwlr(testPoint, xArr, yArr, k = 1.0):
66     """

```

运行结果如下：



可以看到，当 k 越小，拟合效果越好。但是当 k 过小，会出现过拟合的情况，例如 k 等于0.003的时候。

四、预测鲍鱼的年龄

接下来，我们将回归用于真实数据。在abalone.txt文件中记录了鲍鱼（一种水生物→__→）的年龄，这个数据来自UCI数据集的数据。鲍鱼年龄可以从鲍鱼壳的层数推算得到。

数据集下载地址：[数据集下载](#)

数据集的数据如下：

1	1	0.455	0.365	0.095	0.514	0.2245	0.101	0.15	15
2	1	0.35	0.265	0.09	0.2255	0.0995	0.0485	0.07	7
3	-1	0.53	0.42	0.135	0.677	0.2565	0.1415	0.21	9
4	1	0.44	0.365	0.125	0.516	0.2155	0.114	0.155	10
5	0	0.33	0.255	0.08	0.205	0.0895	0.0395	0.055	7
6	0	0.425	0.3	0.095	0.3515	0.141	0.0775	0.12	8
7	-1	0.53	0.415	0.15	0.7775	0.237	0.1415	0.33	20
8	-1	0.545	0.425	0.125	0.768	0.294	0.1495	0.26	16
9	1	0.475	0.37	0.125	0.5095	0.2165	0.1125	0.165	9
10	-1	0.55	0.44	0.15	0.8945	0.3145	0.151	0.32	19
11	-1	0.525	0.38	0.14	0.6065	0.194	0.1475	0.21	14
12	1	0.43	0.35	0.11	0.406	0.1675	0.081	0.135	10
13	1	0.49	0.38	0.135	0.5415	0.2175	0.095	0.19	11
14	-1	0.535	0.405	0.145	0.6845	0.2725	0.171	0.205	10
15	-1	0.47	0.355	0.1	0.4755	0.1675	0.0805	0.185	10
16	1	0.5	0.4	0.13	0.6645	0.258	0.133	0.24	12
17	0	0.355	0.28	0.085	0.2905	0.095	0.0395	0.115	7
18	-1	0.44	0.34	0.1	0.451	0.188	0.087	0.13	10
19	1	0.365	0.295	0.08	0.2555	0.097	0.043	0.1	7
20	1	0.45	0.32	0.1	0.381	0.1705	0.075	0.115	9
21	1	0.355	0.28	0.095	0.2455	0.0955	0.062	0.075	11
22	0	0.38	0.275	0.1	0.2255	0.08	0.049	0.085	10
23	-1	0.565	0.44	0.155	0.9395	0.4275	0.214	0.27	12
24	-1	0.55	0.415	0.135	0.7635	0.318	0.21	0.2	9
25	-1	0.615	0.48	0.165	1.1615	0.513	0.301	0.305	10
26	-1	0.56	0.44	0.14	0.9285	0.3825	0.188	0.3	11
27	-1	0.58	0.45	0.185	0.9955	0.3945	0.272	0.285	11
28	1	0.59	0.445	0.14	0.931	0.356	0.234	0.28	12
29	1	0.605	0.475	0.18	0.9365	0.394	0.219	0.295	15
30	1	0.575	0.425	0.14	0.8635	0.393	0.227	0.2	11
31	1	0.58	0.47	0.165	0.9975	0.3935	0.242	0.33	10
32	-1	0.68	0.56	0.165	1.639	0.6055	0.2805	0.46	15
33	1	0.665	0.525	0.165	1.338	0.5515	0.3575	0.35	18
34	-1	0.68	0.55	0.175	1.798	0.815	0.3925	0.455	19

可以看到，数据集是多维的，所以我们很难画出它的分布情况。每个维度数据的代表的含义没有给出，不过没有关系，我们只要知道最后一列的数据是y值就可以了，最后一列代表的是鲍鱼的真实年龄，前面几列的数据是一些鲍鱼的特征，例如鲍鱼壳的层数等。我们不做数据清理，直接用上所有特征，测试下我们的局部加权回归。

新建abalone.py文件，添加rssError函数，用于评价最后回归结果。编写代码如下：

	Python
1	# -*- coding:utf-8 -*-
2	from matplotlib.font_manager import FontProperties
3	import matplotlib.pyplot as plt
4	import numpy as np
5	def loadDataSet(fileName):
6	"""
7	函数说明:加载数据
8	Parameters:
9	fileName - 文件名
10	Returns:


```

11     xArr = x数据集
12     yArr = y数据集
13     Website:
14     https://www.cuijiahua.com/
15     Modify:
16     2017-11-19
17     """
18     numFeat = len(open(fileName).readline().split('\t')) - 1
19     xArr = []; yArr = []
20     fr = open(fileName)
21     for line in fr.readlines():
22         lineArr = []
23         curLine = line.strip().split('\t')
24         for i in range(numFeat):
25             lineArr.append(float(curLine[i]))
26         xArr.append(lineArr)
27         yArr.append(float(curLine[-1]))
28     return xArr, yArr
29 def lwlr(testPoint, xArr, yArr, k = 1.0):
30     """
31     函数说明:使用局部加权线性回归计算回归系数w
32     Parameters:
33         testPoint - 测试样本点
34         xArr - x数据集
35         yArr - y数据集
36         k - 高斯核的k,自定义参数
37     Returns:
38         ws - 回归系数
39     Website:
40     https://www.cuijiahua.com/
41     Modify:
42     2017-11-19
43     """
44     xMat = np.mat(xArr); yMat = np.mat(yArr).T
45     m = np.shape(xMat)[0]
46     weights = np.mat(np.eye((m)))
47     for j in range(m):
48         diffMat = testPoint - xMat[j, :]
49         weights[j, j] = np.exp(diffMat * diffMat.T / (-2.0 * k**2))
50     xTx = xMat.T * (weights * xMat)
51     if np.linalg.det(xTx) == 0.0:
52         print("矩阵为奇异矩阵,不能求逆")
53         return
54     ws = xTx.I * (xMat.T * (weights * yMat))
55     return testPoint * ws
56 def lwlrTest(testArr, xArr, yArr, k=1.0):
57     """
58     函数说明:局部加权线性回归测试
59     Parameters:
60         testArr - 测试数据集,测试集
61         xArr - x数据集,训练集
62         yArr - y数据集,训练集
63         k - 高斯核的k,自定义参数
64     Returns:
65         ws - 回归系数
66     Website:

```

运行结果如下:

```

128     print('k=0.1时,误差大小为:', rssError(abY[100:199], yHat01.T))
129     print('k=1 时,误差大小为:', rssError(abY[100:199], yHat1.T))
130     print('k=10 时,误差大小为:', rssError(abY[100:199], yHat10.T))
131
132     print('')
133
134     print('训练集与测试集不同:简单的线性回归与k=1时的局部加权线性回归对比:')
135     print('k=1时,误差大小为:', rssError(abY[100:199], yHat1.T))
136     ws = standRegres(abX[0:99], abY[0:99])
137     yHat = np.mat(abX[100:199]) * ws
138     print('简单的线性回归误差大小:', rssError(abY[100:199], yHat.T.A))

```

训练集与测试集相同:局部加权线性回归,核k的大小对预测的影响:

k=0.1时,误差大小为: 56.8121847316
k=1 时,误差大小为: 429.89056187
k=10 时,误差大小为: 549.118170883

训练集与测试集不同:局部加权线性回归,核k的大小是越小越好吗? 更换数据集,测试结果如下:

k=0.1时,误差大小为: 347136.599167
k=1 时,误差大小为: 573.52614419
k=10 时,误差大小为: 517.571190538

训练集与测试集不同:简单的线性回归与k=1时的局部加权线性回归对比:

k=1时,误差大小为: 573.52614419
简单的线性回归误差大小: 518.636315325
[Finished in 2.5s]

可以看到,当 $k=0.1$ 时,训练集误差小,但是应用于新的数据集之后,误差反而变大了。这就是经常说过的过拟合现象。我们训练的模型,我们要保证测试集准确率高,这样训练出的模型才可以应用于新的数据,也就是要加强模型的普适性。可以看到,当 $k=1$ 时,局部加权线性回归和简单的线性回归得到的效果差不多。这也表明一点,必须在未知数据上比较效果才能选取到最佳模型。那么最佳的核大小是10吗?或许是,但如果想得到更好的效果,应该用10个不同的样本集做10次测试来比较结果。

本示例展示了如何使用局部加权线性回归来构建模型,可以得到比普通线性回归更好的效果。局部加权线性回归的问题在于,每次必须在整个数据集上运行。也就是说为了做出预测,必须保存所有的训练数据。

五、总结

- 本文主要介绍了简单的线性回归和局部加权线性回归。
- 训练的模型要在测试集比较它们的效果,而不是在训练集上。
- 在局部加权线性回归中,过小的核可能导致过拟合现象,即训练集表现良好,测试集表现就渣渣了。
- 下篇文章将继续讲解回归,会介绍另一种提高预测精度的方法。
- 如有问题,请留言。如有错误,还望指正,谢谢!

PS: 如果觉得本篇本章对您有所帮助,欢迎关注、评论、赞!

本文出现的所有代码和数据集，均可在我的github上下载，欢迎Follow、Star: [点击查看](#)

参考资料：

- [1] 机器学习实战第八章内容



微信公众号

分享技术，乐享生活：微信公众号搜索
「JackCui-AI」关注一个在互联网摸爬滚
打的潜行者。

如果将梦想作为信仰,不放弃地追求下去,一定会梦想成真的。--- 岸本齐史《火影忍者》